

AVALIAÇÃO DA ESTABILIDADE E FIDELIDADE DE MÉTODOS DE EXPLICABILIDADE PARA REDES NEURAIIS EM GRAFOS

João Victor de Souza Albuquerque

RESUMO

As Redes Neurais em Grafos (Graph Neural Networks – GNNs) têm apresentado resultados expressivos em diversas tarefas envolvendo dados relacionais. Entretanto, sua natureza de caixa-preta dificulta a compreensão do processo de decisão desses modelos, motivando o desenvolvimento de métodos de Inteligência Artificial Explicável (Explainable Artificial Intelligence – XAI). Apesar do crescente número de métodos de explicabilidade para GNNs, ainda existe pouca investigação sobre a confiabilidade das explicações produzidas, especialmente sob a perspectiva de pesquisadores interessados em compreender a evolução do aprendizado dos modelos durante alterações em suas arquiteturas.

Neste trabalho é realizada uma avaliação experimental da confiabilidade de diferentes métodos de explicabilidade para Redes Neurais em Grafos utilizando as métricas de estabilidade e fidelidade. Foram avaliados os métodos GNNExplainer, GraphLIME, Integrated Gradients e LogicXGNN em arquiteturas homogêneas (GCN, GAT e GraphSAGE), além dos métodos Integrated Gradients, Saliency e Attention-based Explanation na arquitetura heterogênea HAN. Os experimentos foram conduzidos utilizando os conjuntos de dados Cora, CiteSeer, PubMed e DBLP. Como contribuição adicional, foi proposta uma etapa de conformidade entre variantes dos modelos antes da avaliação da estabilidade e desenvolvida uma adaptação do método LogicXGNN para permitir sua aplicação em tarefas de classificação de nós.

Os resultados demonstraram que o Integrated Gradients apresentou o melhor equilíbrio entre estabilidade e fidelidade em todos os cenários avaliados, produzindo explicações simultaneamente consistentes entre diferentes variantes dos modelos e representativas do processo de decisão das GNNs. Os experimentos também evidenciaram limitações da estratégia tradicional de avaliação da fidelidade em grafos heterogêneos, indicando a necessidade de métricas que considerem explicitamente a influência das diferentes relações presentes nesse tipo de estrutura.

Palavras-chave: Redes Neurais em Grafos; Inteligência Artificial Explicável; Explicabilidade; Graph Neural Networks; Estabilidade; Fidelidade;

ABSTRACT

Graph Neural Networks (GNNs) have achieved remarkable performance in several tasks involving relational data. However, their black-box nature makes it difficult to understand the reasoning behind their predictions, motivating the development of Explainable Artificial Intelligence (XAI) methods. Although numerous explanation techniques for GNNs have recently been proposed, limited attention has been given to assessing the reliability of the explanations they produce, particularly from the perspective of researchers interested in analyzing how explanations evolve as the model architecture changes.

This work presents an experimental evaluation of the reliability of different explanation methods for Graph Neural Networks using stability and fidelity as evaluation criteria. GNNExplainer, GraphLIME, Integrated Gradients, and LogicXGNN were evaluated on homogeneous GNN architectures (GCN, GAT, and GraphSAGE), while Integrated Gradients, Saliency, and Attention-based Explanation were evaluated on the heterogeneous HAN architecture. Experiments were conducted using the Cora, CiteSeer, PubMed, and DBLP datasets. Additionally, this work proposes a conformity analysis to ensure prediction consistency among model variants before stability evaluation and extends LogicXGNN to support node classification tasks.

Experimental results show that Integrated Gradients achieved the best balance between stability and fidelity across all evaluated scenarios, producing explanations that are both consistent across model variants and highly representative of the GNN decision-making process. Furthermore, the experiments reveal limitations of traditional fidelity evaluation strategies in heterogeneous graphs, suggesting the need for new evaluation metrics that explicitly consider the influence of heterogeneous graph relations.

Keywords: Graph Neural Networks; Explainable Artificial Intelligence. Explainability; Stability; Fidelity; Graph Explainability;

1 INTRODUÇÃO

Nos últimos anos, o aprendizado de máquina aplicado a dados estruturados em grafos

tem recebido crescente atenção da comunidade científica. Diferentemente dos dados tabulares tradicionais, grafos permitem representar explicitamente relações entre entidades, tornando-se uma estrutura de dados adequada para diversos domínios, como redes sociais, sistemas de recomendação, redes de citações científicas, sistemas biológicos e redes de transporte. Nesse contexto, as Redes Neurais em Grafos (Graph Neural Networks – GNNs) consolidaram-se como uma das principais abordagens para tarefas como classificação de nós, classificação de grafos, predição de links e recomendação, alcançando desempenho superior a diversos métodos tradicionais.

Apesar do elevado desempenho obtido por essas arquiteturas, as GNNs apresentam um problema semelhante ao observado em outros modelos baseados em Deep Learning: sua reduzida interpretabilidade. Em geral, essas redes são capazes de produzir previsões altamente precisas, porém oferecem pouca informação sobre os fatores que motivaram determinada decisão. Essa característica dificulta sua utilização em aplicações nas quais compreender o processo de decisão do modelo é tão importante quanto sua capacidade preditiva.

Com o objetivo de reduzir esse problema, surgiu a área de Inteligência Artificial Explicável (Explainable Artificial Intelligence – XAI), cujo principal propósito é desenvolver métodos capazes de tornar modelos complexos mais transparentes e interpretáveis. Nos últimos anos, diversos métodos de explicabilidade foram propostos especificamente para Redes Neurais em Grafos, incluindo abordagens baseadas em máscaras sobre atributos e arestas, gradientes, modelos locais interpretáveis e, mais recentemente, regras simbólicas derivadas das representações internas aprendidas pelas GNNs.

Entretanto, o crescimento do número de métodos de explicabilidade trouxe uma nova questão: como avaliar a qualidade das explicações produzidas por esses métodos? Diferentes explicadores frequentemente fornecem interpretações distintas para uma mesma predição, tornando necessária a utilização de critérios objetivos para comparar sua confiabilidade.

A resposta para essa questão depende diretamente da finalidade da explicação. Em aplicações voltadas ao usuário final, o principal interesse normalmente está relacionado à interpretabilidade e à facilidade de compreensão das explicações. Por outro lado, quando as explicações são utilizadas como ferramenta de análise por pesquisadores e desenvolvedores, outros aspectos tornam-se igualmente importantes, como a capacidade do método de produzir explicações consistentes ao longo de diferentes versões do modelo e de identificar corretamente os fatores que efetivamente influenciam suas decisões.

Neste trabalho, foi adotada a segunda perspectiva. O foco da pesquisa está na utilização de métodos de explicabilidade como ferramenta para analisar a evolução do aprendizado de Redes Neurais em Grafos durante pequenas modificações em suas arquiteturas. Nesse cenário, espera-se que alterações moderadas nos hiperparâmetros produzam mudanças coerentes nas explicações, refletindo a evolução do modelo e não apenas variações decorrentes da aleatoriedade do processo de treinamento.

Para avaliar essa propriedade, foram selecionadas duas métricas amplamente utilizadas na literatura: estabilidade e fidelidade. A estabilidade busca verificar se pequenas alterações na arquitetura da GNN produzem explicações semelhantes para um mesmo conjunto de exemplos. Já a fidelidade mede o quanto os atributos apontados como relevantes realmente influenciam a decisão tomada pelo modelo. Em conjunto, essas métricas permitem avaliar não apenas a consistência das explicações, mas também sua representatividade em relação ao processo de decisão da rede.

Outra delimitação importante desta pesquisa diz respeito ao tipo de grafo considerado. Existem dois grandes cenários de aplicação das Redes Neurais em Grafos: grafos homogêneos, nos quais todos os nós e arestas pertencem ao mesmo tipo, e grafos heterogêneos, compostos por múltiplos tipos de entidades e relações. Embora ambos tenham sido investigados neste trabalho, o foco principal concentrou-se nos grafos homogêneos, devido à maior disponibilidade de métodos de explicabilidade voltados para tarefas de classificação de nós, cenário amplamente utilizado como benchmark na literatura.

Para os experimentos em grafos homogêneos foram selecionados os métodos de explicabilidade GNNExplainer, GraphLIME, Integrated Gradients e LogicXGNN. Esses métodos representam diferentes estratégias para geração de explicações, incluindo otimização baseada em máscaras, modelos interpretáveis locais, atribuição por gradientes e indução de regras simbólicas. No cenário heterogêneo foram avaliados os métodos Integrated Gradients, Saliency e Attention-based Explanation, selecionados por representarem as principais abordagens atualmente disponíveis para arquiteturas heterogêneas.

Como modelos de Redes Neurais em Grafos foram utilizadas as arquiteturas GCN, GAT e GraphSAGE no cenário homogêneo, por serem modelos clássicos amplamente empregados na literatura, além da arquitetura HAN para grafos heterogêneos. Os experimentos foram conduzidos utilizando os conjuntos de dados Cora, CiteSeer e PubMed para grafos homogêneos e o conjunto DBLP para grafos heterogêneos, todos amplamente utilizados na avaliação de

métodos de classificação de nós.

Além da comparação entre diferentes métodos de explicabilidade, este trabalho também propõe duas contribuições adicionais. A primeira consiste na introdução de uma etapa de conformidade entre variantes das arquiteturas antes da avaliação da estabilidade, garantindo que as comparações sejam realizadas apenas entre modelos que apresentem comportamento semelhante em relação às suas predições. A segunda contribuição corresponde à adaptação do método LogicXGNN, originalmente desenvolvido para classificação de grafos, permitindo sua aplicação em tarefas de classificação de nós.

Os resultados experimentais demonstram que o Integrated Gradients apresentou o melhor equilíbrio entre estabilidade e fidelidade, produzindo explicações simultaneamente consistentes entre diferentes variantes dos modelos e representativas do processo de decisão das Redes Neurais em Grafos. Os experimentos também evidenciaram limitações das métricas tradicionais de fidelidade quando aplicadas ao cenário de grafos heterogêneos, indicando a necessidade de estratégias de avaliação que considerem explicitamente a estrutura relacional dos grafos.

A organização deste trabalho é a seguinte. O Capítulo 2 apresenta os principais trabalhos relacionados. O Capítulo 3 descreve os conceitos teóricos necessários para a compreensão do trabalho, incluindo os conjuntos de dados, os modelos de Redes Neurais em Grafos, as métricas de avaliação e os métodos de explicabilidade investigados. O Capítulo 4 apresenta a metodologia experimental adotada. Os resultados obtidos são discutidos no Capítulo 5. Por fim, o Capítulo 6 apresenta as conclusões e as perspectivas para trabalhos futuros.

2 TRABALHOS RELACIONADOS

A crescente utilização de Redes Neurais em Grafos (Graph Neural Networks – GNNs) em aplicações como redes sociais, bioinformática, sistemas de recomendação e redes de citações evidenciou a necessidade de métodos capazes de explicar as decisões produzidas por esses modelos. Nos últimos anos, diversos métodos de Explainable Artificial Intelligence (XAI) para grafos foram propostos, utilizando diferentes estratégias para identificar os fatores responsáveis pelas predições das GNNs. Nesta seção são apresentados os principais trabalhos que fundamentam o desenvolvimento desta pesquisa.

2.1 GNNExplainer

O GNNExplainer, proposto por Ying et al. (??), foi um dos primeiros métodos de explicabilidade desenvolvidos especificamente para Redes Neurais em Grafos. O método busca identificar, para uma determinada predição, o subgrafo e o subconjunto de atributos que mais influenciaram a decisão da rede neural. Para isso, aprende máscaras contínuas sobre as arestas e sobre as features do grafo por meio de um processo de otimização baseado na maximização da informação mútua entre a explicação e a predição do modelo.

O trabalho estabeleceu uma importante base para pesquisas posteriores em explicabilidade para GNNs e tornou-se uma das principais referências da área. Neste trabalho, o GNNExplainer foi utilizado como um dos métodos avaliados experimentalmente, servindo como referência para a análise da estabilidade e da fidelidade das explicações produzidas em diferentes arquiteturas de GNNs.

2.2 GraphLIME

O GraphLIME, proposto por Huang et al. (??), apresenta uma abordagem alternativa para explicabilidade em GNNs baseada na construção de modelos interpretáveis locais. Em vez de otimizar máscaras sobre o grafo, o método utiliza o algoritmo HSIC-Lasso para selecionar as features que apresentam maior dependência estatística com a saída da rede neural na vizinhança do nó analisado.

Essa estratégia produz explicações locais compostas por um conjunto reduzido de atributos relevantes, tornando o processo interpretativo mais simples e eficiente. Neste trabalho, o GraphLIME foi utilizado como representante dos métodos baseados em seleção estatística de atributos, permitindo comparar seu comportamento com abordagens baseadas em otimização e em gradientes.

2.3 HGExplainer

O HGExplainer, proposto por Zhao et al. (ZHAO; AL., 2024), estende os conceitos de explicabilidade para Redes Neurais em Grafos Heterogêneos (Heterogeneous Graph Neural Networks – HGNNs). Diferentemente dos grafos homogêneos, grafos heterogêneos possuem múltiplos tipos de nós e diferentes tipos de relações, tornando a interpretação das decisões significativamente mais complexa.

O método propõe mecanismos específicos para explicar simultaneamente a importância de diferentes tipos de nós, relações e metacaminhos presentes no grafo heterogêneo. Embora o HGExplainer não tenha sido utilizado experimentalmente neste trabalho, sua proposta foi importante para compreender os desafios envolvidos na explicabilidade de grafos heterogêneos e serviu como referência para a adaptação dos experimentos realizados sobre a arquitetura HAN.

2.4 LogicXGNN

Recentemente, Geng et al. (GENG; AL., 2025) propuseram o LogicXGNN, um método de explicabilidade baseado na extração de regras lógicas. Diferentemente da maioria dos métodos existentes, que atribuem escores de importância às features ou às arestas do grafo, o LogicXGNN busca aproximar o comportamento da GNN por meio de regras simbólicas extraídas das representações latentes aprendidas pela rede.

O método converte os embeddings produzidos pela GNN em predicados binários e utiliza uma Árvore de Decisão para induzir regras capazes de reproduzir o comportamento do modelo original. Essa abordagem fornece explicações mais interpretáveis e de fácil compreensão para o usuário final.

Como a implementação disponibilizada pelos autores contempla apenas tarefas de classificação de grafos, neste trabalho foi desenvolvida uma adaptação para possibilitar sua aplicação em tarefas de classificação de nós. Além disso, o LogicXGNN foi avaliado sob os mesmos critérios utilizados para os demais métodos de explicabilidade, incluindo estabilidade, fidelidade e concordância entre as features identificadas.

2.5 GraphXAI

O survey GraphXAI, publicado por Yuan et al. (YUAN; AL., 2024), apresenta uma revisão abrangente dos métodos de explicabilidade para Redes Neurais em Grafos, organizando-os em uma taxonomia baseada nos diferentes paradigmas de explicação. Além de discutir os principais métodos existentes, o trabalho aborda métricas de avaliação, aplicações, desafios e limitações ainda presentes na área.

Entre os diversos aspectos discutidos pelos autores, destacam-se as dificuldades relacionadas à avaliação da qualidade das explicações, especialmente no que se refere às propriedades de estabilidade e fidelidade. O survey evidencia que, embora diversos métodos tenham sido

propostos, ainda existe uma carência de estudos experimentais voltados para a análise da robustez das explicações frente a pequenas alterações nos modelos.

Nesse contexto, o presente trabalho busca contribuir para essa lacuna ao realizar uma avaliação sistemática da estabilidade e da fidelidade de diferentes métodos de explicabilidade em múltiplas arquiteturas de Redes Neurais em Grafos, considerando tanto cenários homogêneos quanto heterogêneos.

Os trabalhos apresentados nesta seção evidenciam a rápida evolução da área de explicabilidade para Redes Neurais em Grafos. Entretanto, observa-se que a maior parte das pesquisas concentra seus esforços no desenvolvimento de novos métodos de explicação, enquanto a avaliação da confiabilidade dessas explicações recebe menor atenção. Em particular, aspectos relacionados à estabilidade e à fidelidade ainda são pouco explorados quando o objetivo é comparar diferentes variantes de uma mesma arquitetura de GNN. Essa lacuna motivou o desenvolvimento deste trabalho, que investiga essas propriedades em diferentes métodos de explicabilidade e arquiteturas de grafos homogêneos e heterogêneos.

3 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os principais conceitos necessários para a compreensão do trabalho desenvolvido. Inicialmente, são descritos os conjuntos de dados utilizados nos experimentos, destacando suas características estruturais e as tarefas de classificação consideradas. Em seguida, são apresentados os modelos de Redes Neurais em Grafos empregados neste trabalho, bem como as métricas utilizadas para avaliar a estabilidade e a fidelidade das explicações produzidas. Por fim, são descritos os métodos de explicabilidade investigados experimentalmente.

3.1 Descrição dos Conjuntos de Dados

Essa seção descreve os datasets usados no trabalho.

3.1.1 Cora

O conjunto de dados Cora consiste em uma rede de citações científicas amplamente utilizada na avaliação de algoritmos de aprendizado em grafos. Nesse conjunto, cada nó representa um artigo científico e cada aresta representa uma relação de citação entre dois artigos. Os artigos são descritos por um vetor contendo 1433 atributos binários, que indicam a presença ou ausência de palavras previamente selecionadas no texto do documento.

Cada artigo pertence a uma dentre sete áreas de pesquisa, correspondentes às classes utilizadas na tarefa de classificação de nós: *Case Based*, *Genetic Algorithms*, *Neural Networks*, *Probabilistic Methods*, *Reinforcement Learning*, *Rule Learning* e *Theory*. No total, o conjunto de dados é composto por 2708 nós e 10556 arestas.(SEN *et al.*, 2008)

3.1.2 CiteSeer

Como o dataset anterior, o citeseer é uma rede de citações científicas, porem com dimensões maiores, sendo composto por 3327 nos com 3703 features cada que representam palavras presente no artigo, e pertencente a uma das 6 classes possíveis, sendo essas i) Agents II) AI III) DB, IV) IR, V) ML e VI) HCI. No total o grafo tem 9104 arestas conectando os artigos. Além do numero de artigos e features. Comparado ao Cora, o CiteSeer apresenta uma estrutura significativamente mais esparsa, menor homofilia entre os nós e maior dimensionalidade dos atributos, fatores que tornam a tarefa de classificação mais desafiadora para modelos baseados em propagação de mensagens.(SEN *et al.*, 2008)

3.1.3 PubMed

Entre os conjuntos homogêneos considerados neste trabalho, o PubMed apresenta a maior quantidade de nós e uma estrutura significativamente mais extensa, composta por aproximadamente vinte mil artigos científicos da área biomédica. Os artigos pertencem a uma das 3 classes, i) Type 1 Diabetes, II) Type 2 Diabetes e III) Experimental Diabetes, todas essas classes pertencendo a diferentes tipos de pesquisa de diabetes mellitus. E todos os grafos são conectados por 88648 arestas.(SEN *et al.*, 2008)

3.1.4 DBLP

O conjunto de dados DBLP é um grafo heterogêneo derivado de uma base bibliográfica da área de Ciência da Computação. Diferentemente dos conjuntos homogêneos utilizados neste trabalho, o DBLP é composto por múltiplos tipos de entidades, incluindo autores, artigos e termos científicos, conectados por diferentes tipos de relações, como autoria de artigos e associação entre artigos e termos. Após a remoção dos nós do tipo Conference, o grafo passou a conter apenas os tipos Author, Paper e Term, preservando as relações entre essas entidades. A tarefa consiste em classificar os nós do tipo Author em uma das quatro áreas de pesquisa disponíveis

(Database, Data Mining, Artificial Intelligence e Information Retrieval).(JI *et al.*, 2020)

3.2 Modelos

As Redes Neurais em Grafos diferenciam-se principalmente pela forma como realizam a agregação das informações provenientes da vizinhança de cada nó. Enquanto algumas arquiteturas utilizam operadores de convolução, outras empregam mecanismos de atenção ou funções explícitas de agregação. Nesta seção são apresentados os modelos utilizados neste trabalho.

3.2.1 *Graph Convolutional Network (GCN)*

A Graph Convolutional Network (GCN), proposta por (KIPF; WELLING, 2017), é uma das arquiteturas mais tradicionais para aprendizado em grafos. Sua principal característica é realizar a propagação de informações entre nós vizinhos por meio de uma operação de convolução definida diretamente sobre a estrutura do grafo.

Em cada camada, a representação de um nó é atualizada pela combinação de suas próprias características com as características de seus vizinhos imediatos. Essa agregação é realizada de forma normalizada utilizando a matriz de adjacência do grafo, permitindo que informações locais sejam incorporadas progressivamente às representações dos nós.

Após duas camadas de convolução, por exemplo, cada nó passa a conter informações provenientes de seus vizinhos e também dos vizinhos desses vizinhos, ampliando o contexto estrutural utilizado durante a classificação.

No presente trabalho, a GCN foi utilizada como modelo de referência devido à sua simplicidade, eficiência computacional e ampla utilização na literatura de aprendizado em grafos. Além disso, diferentes variantes da arquitetura foram treinadas por meio da modificação do número de neurônios na camada oculta e da taxa de dropout, permitindo avaliar a estabilidade dos métodos de explicabilidade frente a pequenas alterações arquiteturais.

3.2.2 *Graph Attention Network (GAT)*

A Graph Attention Network (GAT), proposta por (VELIČKOVIĆ *et al.*, 2018), introduz o mecanismo de atenção ao aprendizado em grafos. Diferentemente da GCN, que considera todos os vizinhos com pesos normalizados semelhantes, a GAT aprende automaticamente a importância relativa de cada vizinho durante o processo de agregação.

Para cada nó, a arquitetura calcula coeficientes de atenção que indicam quanto cada vizinho deve contribuir para a atualização da representação do nó central. Dessa forma, vizinhos mais relevantes recebem maior peso, enquanto vizinhos menos informativos exercem menor influência.

Além disso, a GAT utiliza o mecanismo de multi-head attention, no qual múltiplos mecanismos de atenção são aprendidos simultaneamente. Essa estratégia torna as representações mais robustas e reduz a variância do treinamento.

Neste trabalho, diferentes variantes da GAT foram obtidas modificando-se o número de neurônios ocultos, a taxa de dropout e o número de cabeças de atenção (attention heads), permitindo investigar como essas alterações influenciam a estabilidade das explicações produzidas pelos métodos de Explainable AI.

3.2.3 *GraphSAGE*

O GraphSAGE (Graph Sample and Aggregate), proposto por (HAMILTON *et al.*, 2017), foi desenvolvido com o objetivo de produzir representações capazes de generalizar para nós não observados durante o treinamento.

Ao contrário da GCN, que utiliza uma média normalizada dos vizinhos, o GraphSAGE emprega funções explícitas de agregação para combinar as informações provenientes da vizinhança de cada nó. Entre essas funções estão média (mean), soma (sum), máximo (max pooling) e agregadores baseados em redes neurais.

Após agregar as informações dos vizinhos, o vetor resultante é combinado com as características do próprio nó, produzindo uma nova representação mais expressiva.

Essa estratégia permite que o modelo seja utilizado em cenários indutivos, nos quais novos nós podem ser incorporados ao grafo sem a necessidade de reprocessar toda a estrutura.

Neste trabalho foi utilizada a versão baseada na agregação pela média (mean aggregator), implementada na biblioteca PyTorch Geometric. Assim como nas demais arquiteturas homogêneas, diferentes variantes foram treinadas alterando o número de neurônios ocultos e a taxa de dropout.

3.2.4 *Heterogeneous Graph Attention Network (HAN)*

A Heterogeneous Graph Attention Network (HAN), proposta por (WANG *et al.*, 2019), foi desenvolvida especificamente para grafos heterogêneos, nos quais coexistem diferentes tipos de nós e diferentes tipos de relações.

Enquanto arquiteturas tradicionais como GCN, GAT e GraphSAGE assumem que todos os

nós pertencem ao mesmo tipo, o HAN considera explicitamente a heterogeneidade da estrutura do grafo durante o processo de aprendizado.

A arquitetura emprega mecanismos de atenção em dois níveis distintos. No primeiro nível, denominado node-level attention, o modelo aprende quais vizinhos são mais importantes dentro de um mesmo tipo de relação. No segundo nível, chamado semantic-level attention, o modelo aprende quais relações ou caminhos semânticos (meta-paths) são mais relevantes para a tarefa de classificação.

Dessa forma, o HAN é capaz de combinar informações provenientes de diferentes tipos de entidades e relações, produzindo representações mais expressivas para grafos heterogêneos.

Neste trabalho, o HAN foi utilizado para realizar a classificação dos nós do tipo Author no conjunto de dados DBLP. Foram avaliadas diferentes variantes da arquitetura por meio da alteração do número de neurônios ocultos, do número de cabeças de atenção e da taxa de dropout, permitindo analisar a estabilidade e a fidelidade dos métodos de explicabilidade também em um cenário heterogêneo.

3.3 Descrição das Métricas

A avaliação da qualidade de um método de explicabilidade não depende apenas da capacidade de produzir explicações interpretáveis, mas também da consistência e da representatividade dessas explicações em relação ao comportamento do modelo. Neste trabalho, duas propriedades foram investigadas: estabilidade e fidelidade.

A estabilidade busca verificar se pequenas modificações na arquitetura da Rede Neural em Grafos produzem explicações semelhantes para um mesmo nó. Já a fidelidade avalia se os atributos identificados como importantes realmente influenciam a decisão tomada pelo modelo. Para mensurar essas propriedades foram utilizadas as métricas descritas a seguir.

3.3.1 Similaridade de Jaccard

A Similaridade de Jaccard é uma métrica amplamente utilizada para medir o grau de similaridade entre dois conjuntos. Neste trabalho, essa métrica é empregada para avaliar a estabilidade dos métodos de explicabilidade, comparando os conjuntos de atributos considerados mais relevantes por diferentes variantes de uma mesma arquitetura de Rede Neural em Grafos.

Considere A e B como os conjuntos contendo as k features mais importantes identificadas

por duas variantes distintas do modelo. A Similaridade de Jaccard é definida como:

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|} \quad (3.1)$$

onde $A \cap B$ representa a interseção entre os conjuntos e $A \cup B$ representa sua união.

Os valores da Similaridade de Jaccard pertencem ao intervalo $[0, 1]$. Um valor igual a 1 indica que ambos os conjuntos são idênticos, enquanto um valor igual a 0 indica que não existe nenhuma feature em comum entre as explicações comparadas.

No contexto deste trabalho, valores elevados de Similaridade de Jaccard indicam que pequenas alterações na arquitetura da GNN não modificam significativamente os atributos considerados relevantes pelo método de explicabilidade, caracterizando um comportamento mais estável. (JACCARD, 1901)

3.3.2 *Overlap@k*

Embora a Similaridade de Jaccard considere simultaneamente os elementos em comum e os elementos distintos entre dois conjuntos, também é interessante avaliar apenas quantos atributos permanecem presentes entre as explicações. Para isso, foi utilizada a métrica *Overlap@k*.

Considere A_k e B_k como os conjuntos contendo as k features mais relevantes produzidas por duas variantes distintas da arquitetura. O *Overlap@k* é definido como:

$$Overlap@k(A,B) = |A_k \cap B_k| \quad (3.2)$$

onde $|A_k \cap B_k|$ representa o número de atributos compartilhados entre as duas explicações.

Os valores dessa métrica variam entre 0 e k , sendo que valores próximos de k indicam que praticamente todas as features importantes permaneceram inalteradas entre as variantes avaliadas.

Neste trabalho foi adotado $k = 10$, de forma que valores próximos de 10 representam elevada consistência entre as explicações produzidas pelos diferentes modelos.

3.3.3 *Correlação de Spearman*

Além de identificar os atributos considerados importantes, diversos métodos de explicabilidade também produzem um ranking indicando o grau de relevância de cada feature. Assim,

mesmo que duas explicações contenham os mesmos atributos, a ordem de importância atribuída a eles pode variar.

Para avaliar essa característica foi utilizada a Correlação de Spearman, uma métrica estatística utilizada para medir a concordância entre dois rankings.

Sua definição é dada por:

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (3.3)$$

onde:

- n representa o número de atributos comparados;
- d_i representa a diferença entre as posições ocupadas pelo atributo i nos dois rankings.

O coeficiente assume valores no intervalo $[-1, 1]$, em que:

- $\rho = 1$ indica rankings idênticos;
- $\rho = 0$ indica ausência de correlação;
- $\rho = -1$ indica que os rankings são completamente inversos.

Neste trabalho, a Correlação de Spearman complementa as métricas anteriores ao avaliar não apenas se as mesmas features foram identificadas, mas também se sua ordem de importância permaneceu consistente após pequenas modificações na arquitetura da GNN.(SPEARMAN, 1904)

3.3.4 Fidelity

Enquanto as métricas apresentadas anteriormente avaliam a estabilidade das explicações, a Fidelity mede o quanto as features identificadas pelo método de explicabilidade realmente influenciam a decisão do modelo.

A ideia consiste em mascarar os atributos considerados mais relevantes pelo método de explicabilidade e observar quanto a confiança do modelo na classe originalmente prevista é reduzida.

A Fidelity é calculada por meio da seguinte expressão:

$$Fidelity = P(y | G, X) - P(y | G, X_{masked}) \quad (3.4)$$

onde:

- $P(y | G, X)$ representa a probabilidade atribuída pelo modelo para a classe prevista utilizando o grafo original;
- $P(y | G, X_{masked})$ representa a probabilidade da mesma classe após a remoção das features consideradas mais importantes pelo método de explicabilidade.

Valores elevados de Fidelity indicam que as features identificadas exercem forte influência na decisão do modelo, uma vez que sua remoção reduz significativamente a confiança da predição.

Por outro lado, valores próximos de zero indicam que a remoção dos atributos pouco alterou a saída da rede, sugerindo que as features selecionadas possuem baixa relevância para a decisão do modelo.

Em situações nas quais a Fidelity assume valores negativos, a remoção das features consideradas importantes aumenta a confiança da rede na classe prevista. Esse comportamento indica que a explicação não representa adequadamente os fatores responsáveis pela decisão do modelo.

3.3.5 Considerações sobre as métricas utilizadas

As métricas utilizadas neste trabalho foram selecionadas por avaliarem propriedades complementares das explicações produzidas pelos métodos de Explainable Artificial Intelligence aplicados às Redes Neurais em Grafos.

A Similaridade de Jaccard, o $\text{Overlap}@k$ e a Correlação de Spearman são empregadas para avaliar a **estabilidade** das explicações, verificando se pequenas alterações na arquitetura do modelo preservam os atributos considerados mais relevantes e sua respectiva ordem de importância.

Por sua vez, a métrica de Fidelity é utilizada para avaliar a **fidelidade** das explicações, medindo o impacto causado pela remoção das features identificadas pelo método sobre a confiança da predição do modelo.

Em conjunto, essas métricas permitem analisar tanto a consistência quanto a capacidade explicativa dos métodos avaliados, fornecendo uma visão abrangente sobre sua confiabilidade em diferentes arquiteturas e conjuntos de dados.

3.4 Métodos de Explicabilidade

Os métodos de explicabilidade existentes para Redes Neurais em Grafos podem ser classificados de acordo com a estratégia utilizada para produzir as explicações. Alguns métodos aprendem máscaras sobre a estrutura do grafo ou sobre os atributos de entrada, outros utilizam modelos locais interpretáveis, enquanto abordagens mais recentes exploram gradientes, mecanismos de atenção ou extração de regras simbólicas. Neste trabalho foram selecionados métodos representativos dessas diferentes categorias.

3.4.1 *GNNExplainer*

O GNNExplainer, proposto por Ying et al. (YING *et al.*, 2019), é um dos primeiros métodos de explicabilidade desenvolvidos especificamente para Redes Neurais em Grafos. Seu objetivo consiste em identificar quais componentes do grafo são mais relevantes para a decisão produzida pelo modelo, fornecendo explicações tanto em nível de estrutura quanto de atributos.

O método formula a geração da explicação como um problema de otimização, aprendendo máscaras contínuas aplicadas às arestas e às features do grafo. Essas máscaras são ajustadas de forma a maximizar a informação mútua entre a predição original da rede e a predição obtida utilizando apenas os elementos considerados importantes.

Ao final do processo de otimização, as features que recebem maiores pesos são consideradas as mais relevantes para a decisão do modelo. Neste trabalho, apenas a máscara de atributos foi utilizada, permitindo identificar as features mais importantes para cada nó analisado.

3.4.2 *GraphLIME*

O GraphLIME, proposto por Huang et al. (HUANG *et al.*, 2020), é um método de explicabilidade local inspirado no LIME, porém adaptado para Redes Neurais em Grafos. Diferentemente do GNNExplainer, o GraphLIME não modifica diretamente a estrutura do grafo nem otimiza máscaras sobre os atributos.

Sua abordagem consiste em construir um modelo linear local capaz de aproximar o comportamento da GNN nas proximidades do nó de interesse. Para isso, utiliza o algoritmo Hilbert-Schmidt Independence Criterion Lasso (HSIC-Lasso), responsável por selecionar os atributos que apresentam maior dependência estatística com a saída produzida pela rede neural.

Como resultado, o método identifica um subconjunto reduzido de features capaz de explicar

localmente a decisão da GNN. Por basear-se em seleção estatística de atributos, o GraphLIME tende a produzir explicações mais simples e facilmente interpretáveis.

3.4.3 *Integrated Gradients*

O método Integrated Gradients, proposto por Sundararajan et al. (SUNDARARAJAN *et al.*, 2017), é uma técnica baseada em gradientes amplamente utilizada para interpretação de modelos de aprendizado profundo.

A principal ideia consiste em calcular a contribuição de cada atributo integrando os gradientes da saída do modelo ao longo de um caminho contínuo entre uma entrada de referência (*baseline*) e a entrada original. Dessa forma, o método estima quanto cada feature contribuiu para a decisão final da rede.

Uma das principais vantagens do Integrated Gradients é satisfazer propriedades teóricas importantes, como sensibilidade e completude, tornando suas explicações mais consistentes quando comparadas a métodos baseados apenas em gradientes locais.

Neste trabalho, o método foi empregado para calcular a importância de cada atributo dos nós classificados pelas diferentes arquiteturas de Redes Neurais em Grafos.

3.4.4 *LogicXGNN*

O LogicXGNN, proposto por Geng et al. (GENG; AL., 2025), é um método de explicabilidade baseado em regras lógicas, desenvolvido para fornecer explicações simbólicas para Redes Neurais em Grafos.

Diferentemente dos métodos tradicionais, que normalmente atribuem escores de importância às features ou às arestas do grafo, o LogicXGNN busca aproximar o comportamento da GNN por meio de regras lógicas extraídas das representações latentes aprendidas pela rede. Inicialmente, são obtidos os embeddings produzidos pela última camada oculta da GNN. Em seguida, essas representações são convertidas em predicados binários utilizando limiares obtidos automaticamente. Por fim, uma Árvore de Decisão é treinada sobre esses predicados para extrair regras capazes de reproduzir o comportamento do modelo.

Como a implementação original disponibilizada pelos autores contempla apenas tarefas de classificação de grafos, neste trabalho foi desenvolvida uma adaptação para permitir sua aplicação em problemas de classificação de nós. Após essa adaptação, o método foi submetido ao mesmo protocolo experimental empregado para os demais explicadores, sendo avaliadas sua

estabilidade, fidelidade e concordância com as features identificadas pelos outros métodos de explicabilidade.

3.4.5 *Saliency*

O método Saliency é uma das técnicas mais simples para interpretação de modelos baseados em redes neurais. Sua ideia consiste em utilizar diretamente o gradiente da saída do modelo em relação às features de entrada.

A magnitude do gradiente indica o quanto pequenas alterações em determinado atributo influenciam a saída produzida pela rede. Assim, atributos associados a gradientes de maior magnitude são considerados mais relevantes para a decisão do modelo.

Embora seja computacionalmente eficiente, o método apresenta algumas limitações, como elevada sensibilidade a ruídos e possíveis problemas de saturação dos gradientes. Ainda assim, devido à sua simplicidade e ampla utilização na literatura, o Saliency constitui um importante método de referência para avaliação de explicações baseadas em gradientes.

3.4.6 *Attention-based Feature Explanation*

Para o cenário heterogêneo, utilizando a arquitetura HAN, também foi avaliado um método de explicação baseado nos pesos de atenção aprendidos pela própria rede.

A HAN emprega mecanismos de atenção para ponderar a importância relativa das informações provenientes de diferentes vizinhos e diferentes relações semânticas durante o processo de propagação de mensagens. Dessa forma, os pesos de atenção aprendidos podem ser utilizados como um indicativo da relevância das informações utilizadas pelo modelo para realizar determinada classificação.

Neste trabalho, os pesos de atenção foram combinados com os atributos dos nós para produzir um ranking de importância das features de entrada. Embora esse método não realize um processo explícito de otimização ou atribuição de importância, ele fornece uma interpretação direta do comportamento do mecanismo de atenção aprendido pela rede.

4 METODOLOGIA

4.1 Preparação dos modelos

4.1.1 *Treinamento e seleção dos modelos*

Para o processo de treinamento, primeiro foram criados de 9 a 12 variantes de cada um dos modelos, após isso, essas variantes são treinadas com o otimizador adam, com passo de aprendizagem 0,01, por 200 épocas para cada um dos datasets. Essas variantes de cada dataset são salvas para seleção.

Para cada dataset e modelo, suas variantes tem o desempenho no conjunto de teste avaliado e usado para escolher entre as variantes da combinação, as três variantes que tiveram o melhor desempenho na tarefa de classificação de nós.

4.1.2 *Conformidade*

Embora as variantes apresentem desempenhos semelhantes em termos de acurácia, isso não implica que elas realizem corretamente a classificação dos mesmos nós. Dois modelos podem atingir a mesma acurácia classificando corretamente subconjuntos distintos do conjunto de teste. Nesse cenário, diferenças entre as explicações poderiam ser consequência de divergências nas predições realizadas pelos modelos, e não necessariamente de instabilidade do método de explicabilidade.

Para evitar esse problema, foi proposta uma etapa de análise de conformidade entre as variantes selecionadas. Inicialmente, cada variante classificou novamente o conjunto de teste. Em seguida, foram calculadas as taxas de concordância par a par e globalmente, considerando apenas os nós corretamente classificados por todas as variantes. Dessa forma, garantiu-se que a análise de estabilidade fosse realizada apenas sobre exemplos para os quais os modelos apresentavam comportamento consistente.

4.2 Estabilidade

Esse procedimento foi usado no cenário homogêneo e no cenário heterogêneo

4.2.1 Seleção de Nós

A avaliação da estabilidade requer que todos os métodos produzam explicações para exatamente o mesmo conjunto de exemplos. Dessa forma, foi realizada uma etapa de seleção dos nós que seriam utilizados ao longo de todos os experimentos. Essa escolha pode ser feita de diferentes maneiras, a escolhida nesse artigo foi de pegar aleatoriamente vinte nós do conjunto teste de cada dataset que foram classificados corretamente pelas variantes e nas quais elas concordam na classificação. Esse recorte de nós foi escolhido pois ele garante que os nós escolhidos são visto de forma parecida por todas as variantes do par modelo e dataset.

4.2.2 Explicação

Após a seleção dos nós, foram geradas as explicações utilizando cada um dos métodos de XAI avaliados. Cada par de modelos variantes e datasets foram passados junto do método de explicação para uma função que classifica os nós selecionados e em seguida produz a explicação de cada um desses nós com o método escolhido, no fim a função devolve a explicação de cada um dos nós para cada um dos modelos, essas explicações são salvas para serem usadas no decorrer da pesquisa.

4.2.3 Calculo de Estabilidade

Agora na parte principal do experimento de estabilidade, foram realizadas duas análises complementares de estabilidade, uma global, analisando o quanto muda a explicação entre as três variantes e uma análise em pá para saber o quanto a explicação muda entre um pá de variantes. Para fazer essas análises, as explicações e os nós selecionados são passados para as funções que calculam as diferenças dos conjuntos de explicação, usando as métricas de jaccard, overlap e spearman, essas métricas foram escolhidas se complementarem entre si.

4.3 Fidelidade

As explicações e os nós são os mesmos da parte de estabilidade para se ter uma consistência de análise entre as duas partes, por tanto não é necessária reexplicá-las. Agora indo para a parte principal da análise de fidelidade, a fidelidade foi avaliada em dois níveis. Inicialmente, foi calculada a fidelidade individual de cada nó, permitindo analisar a qualidade local das

explicações. Posteriormente, os resultados foram agregados para obtenção da fidelidade global de cada método de explicabilidade, utilizada na comparação entre arquiteturas e conjuntos de dados. Os modelos variantes, as explicações desses modelos, os nós selecionados e os dados são passado para uma função que calcula a fidelidade da explicação de cada nó de cada modelo, no fim a função responde um dataframe com a fidelidade media de todos os nós e a fidelidade global corresponde à média da fidelidade obtida para todos os nós selecionados.

4.4 LogicXGNN

Além dos métodos de explicabilidade tradicionalmente utilizados para Redes Neurais em Grafos, foi avaliado o método LogicXGNN (AUTOR et al., 2025). Como a implementação disponibilizada pelos autores contempla apenas explicações para tarefas de classificação de grafos, foi realizada uma adaptação para possibilitar sua aplicação em tarefas de classificação de nós, cenário considerado neste trabalho.

A adaptação consistiu na substituição da etapa de obtenção de embeddings em nível de grafo pela extração da representação latente do nó de interesse produzida pela última camada oculta da GNN. Essas representações foram utilizadas para gerar os predicados binários empregados na indução das regras lógicas.

O LogicXGNN foi selecionado por produzir explicações na forma de regras lógicas, diferentemente dos demais métodos avaliados, que normalmente atribuem escores de importância às features ou às arestas do grafo. Essa característica torna suas explicações mais interpretáveis para o usuário, permitindo descrever explicitamente as condições que levaram o modelo à decisão.

Após a adaptação, o método foi submetido ao mesmo protocolo experimental adotado para os demais explicadores, sendo avaliadas as métricas de estabilidade e fidelidade. Adicionalmente, foi realizada uma análise de concordância entre as features originais mapeadas a partir das regras lógicas produzidas pelo LogicXGNN e as features identificadas pelos demais métodos de explicabilidade. Essa comparação teve como objetivo investigar o grau de convergência entre explicações baseadas em regras simbólicas e explicações baseadas em atribuição de importância às features.

5 RESULTADOS

5.1 Conformidade

Antes da avaliação da estabilidade dos métodos de explicabilidade, foi realizada uma análise de conformidade entre as variantes de cada arquitetura selecionadas para os experimentos. Essa etapa é necessária porque modelos com desempenhos semelhantes em termos de acurácia não necessariamente realizam corretamente a classificação do mesmo conjunto de nós.

Por exemplo, considere duas variantes que obtenham aproximadamente 80% de acurácia no conjunto de teste. Embora apresentem desempenhos equivalentes, é possível que uma parcela significativa dos nós corretamente classificados por uma variante seja diferente daquela corretamente classificada pela outra. Nesse cenário, diferenças observadas entre as explicações poderiam ser consequência das divergências nas predições realizadas pelos modelos e não, necessariamente, da estabilidade do método de explicabilidade avaliado.

Para evitar esse problema, foi proposto um teste de conformidade entre as variantes selecionadas. Inicialmente, cada variante realizou novamente a classificação do conjunto de teste. Em seguida, foi calculada a porcentagem de nós corretamente classificados em comum pelas variantes, tanto de forma global quanto por meio de comparações par a par. Dessa forma, foi possível verificar se os modelos apresentavam comportamento semelhante antes da realização da análise de estabilidade.

Os resultados da análise global de conformidade são apresentados na Tabela 1. Observa-se que a maioria das combinações entre arquitetura e conjunto de dados apresentou conformidade superior a 90%, indicando elevada concordância entre as variantes selecionadas. Esse resultado demonstra que, apesar das pequenas modificações realizadas nos hiperparâmetros, os modelos tendem a aprender padrões semelhantes e produzir predições consistentes para a maior parte dos nós do conjunto de teste.

A única exceção foi observada para a arquitetura GAT no conjunto CiteSeer, cuja conformidade global foi de 78,20%. Embora esse valor seja inferior aos demais resultados, uma análise mais detalhada das comparações par a par, apresentada no Apêndice A, mostrou que todas as combinações entre variantes apresentaram concordância superior a 80%. Dessa forma, conclui-se que, mesmo nesse caso, existe consistência suficiente entre as variantes para prosseguir com a avaliação da estabilidade dos métodos de explicabilidade.

Em conjunto, esses resultados fornecem evidências de que as diferenças observadas posteri-

ormente entre as explicações produzidas pelos métodos estão predominantemente relacionadas ao comportamento dos próprios explicadores e não a divergências nas predições realizadas pelas variantes dos modelos avaliados.

Tabela 1 – Resultados de conformidade entre as variantes de cada arquitetura.

Modelo	Dataset	Conformidade (%)
GCN	Cora	92.40
GCN	CiteSeer	91.50
GCN	PubMed	95.70
HAN	DBLP	88.09
GAT	Cora	88.40
GAT	CiteSeer	78.20
GAT	PubMed	91.40
GraphSAGE	Cora	91.10
GraphSAGE	CiteSeer	91.00
GraphSAGE	PubMed	91.70

Fonte: Elaborado pelo autor.

5.2 Estabilidade

5.2.1 Estabilidade dos grafos homogêneos

Esta seção apresenta os resultados da avaliação da estabilidade dos métodos de explicabilidade considerados neste trabalho. O objetivo dessa análise é verificar se pequenas alterações na arquitetura das Redes Neurais em Grafos produzem mudanças significativas nas explicações geradas para um mesmo conjunto de nós. Dessa forma, um método pode ser considerado estável quando produz explicações semelhantes mesmo após pequenas modificações nos hiperparâmetros do modelo.

A estabilidade foi avaliada utilizando as métricas de Similaridade de Jaccard, Overlap@10 e Correlação de Spearman, apresentadas na Seção 3.3. Enquanto a Similaridade de Jaccard e o Overlap@10 medem o grau de concordância entre os conjuntos de atributos identificados pelos explicadores, a Correlação de Spearman avalia se esses atributos permanecem aproximadamente na mesma ordem de importância.

Os resultados obtidos para os grafos homogêneos são apresentados na Tabela 2.

Analisando inicialmente os resultados do **GNNExplainer**, observa-se uma redução gradual da estabilidade à medida que aumenta a complexidade dos conjuntos de dados. Enquanto no

conjunto Cora os valores de Similaridade de Jaccard variam entre aproximadamente 0,58 e 0,70, nos conjuntos CiteSeer e PubMed esses valores diminuem significativamente, chegando a aproximadamente 0,23 para a arquitetura GAT no PubMed. Comportamento semelhante também pode ser observado na métrica Overlap@10, indicando que diferentes variantes do modelo tendem a selecionar conjuntos distintos de atributos relevantes conforme aumenta a dificuldade da tarefa de classificação. Esses resultados sugerem que as explicações produzidas pelo GNNExplainer apresentam sensibilidade às pequenas modificações realizadas na arquitetura da GNN.

O **GraphLIME** apresentou um comportamento diferente. Embora seus valores de Similaridade de Jaccard sejam, em geral, inferiores aos obtidos pelo Integrated Gradients, observa-se que a estabilidade permanece relativamente constante entre os diferentes conjuntos de dados e arquiteturas avaliadas. Os valores de Jaccard concentram-se entre aproximadamente 0,50 e 0,70, enquanto o Overlap@10 permanece próximo de seis a oito atributos compartilhados entre as variantes. Além disso, os coeficientes de Spearman permaneceram consistentemente positivos e relativamente elevados, indicando que o método preserva não apenas parte dos atributos selecionados, mas também sua ordem de importância. Esses resultados indicam que o GraphLIME produz explicações relativamente consistentes independentemente da complexidade do conjunto de dados.

Entre todos os métodos avaliados, o **Integrated Gradients** apresentou os melhores resultados de estabilidade. Em praticamente todos os experimentos foram observados elevados valores de Similaridade de Jaccard, frequentemente superiores a 0,75 e alcançando aproximadamente 0,89 no conjunto PubMed utilizando a arquitetura GCN. De maneira semelhante, os valores de Overlap@10 permaneceram próximos de nove atributos compartilhados entre as variantes, enquanto os coeficientes de Spearman apresentaram valores elevados em praticamente todos os experimentos. Esses resultados demonstram que pequenas alterações na arquitetura dos modelos exercem baixa influência sobre as explicações produzidas pelo Integrated Gradients, tornando-o o método mais consistente entre os avaliados.

Os resultados obtidos pelo **LogicXGNN** diferem significativamente dos demais métodos. Em geral, foram observados baixos valores de Similaridade de Jaccard e Overlap@10, indicando que diferentes variantes tendem a produzir conjuntos distintos de atributos após o processo de mapeamento das regras lógicas para as features originais. Em contrapartida, os coeficientes de Spearman permaneceram elevados em diversas configurações, principalmente para as arquiteturas

GCN e GraphSAGE. Esse comportamento aparentemente contraditório sugere que, embora o conjunto de atributos selecionados varie entre as variantes, parte da ordenação relativa das explicações permanece semelhante.

Uma possível explicação para esse comportamento está relacionada ao funcionamento interno do LogicXGNN. Diferentemente dos demais métodos, suas regras são construídas a partir dos embeddings produzidos pela última camada oculta da GNN. Como pequenas alterações na arquitetura podem modificar a organização do espaço latente aprendido pelo modelo, o processo de mapeamento dessas dimensões latentes para os atributos originais também tende a variar entre as variantes. Consequentemente, diferentes conjuntos de atributos podem ser associados às regras lógicas, reduzindo os valores de Similaridade de Jaccard sem necessariamente alterar de forma significativa a importância relativa das representações latentes utilizadas durante a decisão.

De forma geral, os resultados obtidos para os grafos homogêneos indicam que o Integrated Gradients foi o método mais estável entre todos os explicadores avaliados, apresentando elevado grau de concordância entre as variantes independentemente da arquitetura utilizada ou da complexidade do conjunto de dados. O GraphLIME apresentou estabilidade intermediária, enquanto o GNNExplainer demonstrou maior sensibilidade às modificações realizadas nas arquiteturas. Por fim, embora o LogicXGNN produza explicações altamente interpretáveis por meio de regras lógicas, as métricas utilizadas neste trabalho indicam que seu processo de mapeamento para atributos originais apresenta menor consistência entre diferentes variantes do modelo.

5.2.2 Estabilidade dos grafos heterogêneos

Após a avaliação dos métodos de explicabilidade em grafos homogêneos, foi realizada a mesma análise utilizando o conjunto de dados DBLP e a arquitetura HAN, representando o cenário de grafos heterogêneos. Os resultados obtidos são apresentados na Tabela 5.

Observa-se que o **Integrated Gradients** novamente apresentou o melhor desempenho entre os métodos avaliados. O método obteve Similaridade de Jaccard igual a 0,745, Overlap@10 de 8,217 e Correlação de Spearman de 0,538, indicando elevada consistência entre as explicações produzidas pelas diferentes variantes da arquitetura HAN. Esses resultados demonstram que pequenas alterações nos hiperparâmetros do modelo exercem pouca influência sobre os atributos considerados relevantes pelo explicador, mesmo em um cenário caracterizado por múltiplos tipos de nós e relações.

Tabela 2 – Resultados da avaliação de estabilidade dos métodos de explicabilidade homogêneos utilizando as métricas de Similaridade de Jaccard, Overlap@10 e Correlação de Spearman.

Dataset	Modelo	Explicador	Jaccard	Overlap@10	Spearman	Jaccard Std
GNNExplainer						
Cora	GCN	GNNExplainer	0.704	8.150	0.234	0.148
Cora	GAT	GNNExplainer	0.580	7.100	0.129	0.206
Cora	GraphSAGE	GNNExplainer	0.680	7.900	0.271	0.203
CiteSeer	GCN	GNNExplainer	0.408	5.483	-0.138	0.205
CiteSeer	GAT	GNNExplainer	0.342	4.983	-0.015	0.083
CiteSeer	GraphSAGE	GNNExplainer	0.452	6.067	0.038	0.143
PubMed	GCN	GNNExplainer	0.265	4.017	-0.064	0.119
PubMed	GAT	GNNExplainer	0.229	3.517	-0.079	0.133
PubMed	GraphSAGE	GNNExplainer	0.283	4.133	-0.009	0.160
GraphLIME						
Cora	GCN	GraphLIME	0.524	6.283	0.633	0.313
Cora	GAT	GraphLIME	0.735	7.983	0.787	0.320
Cora	GraphSAGE	GraphLIME	0.504	5.950	0.479	0.340
CiteSeer	GCN	GraphLIME	0.656	7.367	0.606	0.322
CiteSeer	GAT	GraphLIME	0.694	7.567	0.710	0.311
CiteSeer	GraphSAGE	GraphLIME	0.562	6.467	0.574	0.352
PubMed	GCN	GraphLIME	0.502	6.067	0.477	0.268
PubMed	GAT	GraphLIME	0.386	4.717	0.455	0.356
PubMed	GraphSAGE	GraphLIME	0.502	5.883	0.447	0.360
Integrated Gradients						
Cora	GCN	Integrated Gradients	0.800	8.817	0.894	0.109
Cora	GAT	Integrated Gradients	0.672	7.900	0.730	0.160
Cora	GraphSAGE	Integrated Gradients	0.797	8.800	0.876	0.116
CiteSeer	GCN	Integrated Gradients	0.830	9.017	0.919	0.110
CiteSeer	GAT	Integrated Gradients	0.583	7.283	0.595	0.101
CiteSeer	GraphSAGE	Integrated Gradients	0.756	8.550	0.902	0.107
PubMed	GCN	Integrated Gradients	0.887	9.367	0.935	0.088
PubMed	GAT	Integrated Gradients	0.684	8.067	0.862	0.087
PubMed	GraphSAGE	Integrated Gradients	0.823	8.967	0.847	0.111
LogicXGNN						
Cora	GCN	LogicXGNN	0.264	4.056	0.954	0.110
Cora	GAT	LogicXGNN	0.025	0.461	0.077	0.027
Cora	GraphSAGE	LogicXGNN	0.220	3.380	0.713	0.093
CiteSeer	GCN	LogicXGNN	0.309	4.458	0.953	0.110
CiteSeer	GAT	LogicXGNN	0.018	0.333	0.083	0.019
CiteSeer	GraphSAGE	LogicXGNN	0.217	3.400	0.863	0.074
PubMed	GCN	LogicXGNN	0.460	5.812	0.763	0.214
PubMed	GAT	LogicXGNN	0.150	2.450	0.673	0.076
PubMed	GraphSAGE	LogicXGNN	0.396	5.333	0.898	0.132

Fonte: Elaborado pelo autor.

O método **Saliency** apresentou desempenho significativamente inferior ao observado para o Integrated Gradients. Embora seja baseado em gradientes, seus valores de Similaridade de Jaccard (0,239) e Overlap@10 (2,700) indicam baixa concordância entre as explicações geradas pelas variantes do modelo. A Correlação de Spearman também apresentou valor reduzido (0,185), sugerindo que tanto o conjunto de atributos selecionados quanto sua ordem de importância variam consideravelmente entre as diferentes variantes da arquitetura.

O pior desempenho foi obtido pelo método baseado em atenção (**Attention-based Explanation**). Todas as métricas apresentaram valores muito baixos, destacando-se a Similaridade de Jaccard de apenas 0,052 e Overlap@10 inferior a um atributo em média. Esses resultados indicam que os pesos de atenção aprendidos pela arquitetura HAN sofrem grande variação entre pequenas modificações dos hiperparâmetros, tornando esse mecanismo pouco consistente como fonte de explicações quando analisado sob a perspectiva da estabilidade.

Comparando os resultados obtidos nos cenários homogêneo e heterogêneo, observa-se que o comportamento relativo dos métodos permaneceu consistente. O Integrated Gradients manteve o melhor desempenho em ambos os cenários, enquanto métodos baseados diretamente em gradientes simples ou em mecanismos de atenção apresentaram menor estabilidade. Esse resultado é particularmente relevante, pois demonstra que o desempenho do Integrated Gradients não depende da homogeneidade da estrutura do grafo, sendo capaz de produzir explicações consistentes mesmo em problemas envolvendo múltiplos tipos de nós e relações.

De maneira geral, os experimentos realizados no cenário heterogêneo reforçam a principal conclusão desta etapa do trabalho: entre todos os métodos avaliados, o Integrated Gradients apresentou o maior nível de estabilidade, mostrando-se o método mais adequado para investigar a evolução do aprendizado de Redes Neurais em Grafos sob pequenas modificações em suas arquiteturas.

Tabela 3 – Resultados da avaliação de estabilidade dos métodos de explicabilidade heterogêneos utilizando as métricas de Similaridade de Jaccard, Overlap@10 e Correlação de Spearman.

Dataset	Modelo	Explicador	Jaccard	Overlap@10	Spearman	Jaccard Std
DBLP	HAN	Integrated Gradients	0.745	8.217	0.538	0.279
DBLP	HAN	Saliency	0.239	2.700	0.185	0.392
DBLP	HAN	Attention-based explanation	0.052	0.950	0.033	0.026

Fonte: Elaborado pelo autor.

5.3 Fidelidade dos grafos homogêneos

5.3.1 Fidelidade dos grafos homogêneos

Após a análise da estabilidade, foi realizada a avaliação da fidelidade dos métodos de explicabilidade. Diferentemente da estabilidade, que busca verificar a consistência das explicações entre diferentes variantes do modelo, a fidelidade tem como objetivo avaliar se os atributos identificados como relevantes realmente influenciam a decisão tomada pela Rede Neural em Grafos.

Os resultados obtidos para os grafos homogêneos são apresentados na Tabela 4.

Analisando inicialmente os resultados do **GNExplainer**, observa-se que o método apresentou valores intermediários de fidelidade em todos os conjuntos de dados avaliados. Os maiores valores foram obtidos para a arquitetura GraphSAGE no conjunto CiteSeer (0,257) e para a arquitetura GCN no mesmo conjunto (0,224), enquanto os menores valores foram observados no conjunto PubMed, principalmente utilizando a arquitetura GAT (0,063). Esses resultados indicam que, embora o GNExplainer seja capaz de identificar atributos relevantes para a decisão do modelo, parte das features selecionadas possui influência limitada sobre a predição final.

O **GraphLIME** apresentou os menores valores de fidelidade entre todos os métodos avaliados. Em praticamente todas as combinações entre arquitetura e conjunto de dados, os valores permaneceram próximos de zero, chegando inclusive a apresentar pequenas fidelidades negativas em algumas configurações. Esse comportamento indica que o mascaramento dos atributos selecionados produziu pouca ou nenhuma alteração na confiança da GNN para a classe originalmente prevista, sugerindo que grande parte das features identificadas pelo método exerce baixa influência sobre a decisão do modelo segundo a métrica de fidelidade adotada neste trabalho.

Por outro lado, o **Integrated Gradients** apresentou os maiores valores de fidelidade em todos os experimentos realizados. Os melhores resultados foram observados utilizando a arquitetura GraphSAGE no conjunto CiteSeer (0,339), seguida pela arquitetura GCN no mesmo conjunto (0,305). Mesmo nos cenários mais desafiadores, como o conjunto PubMed, os valores permaneceram significativamente superiores aos obtidos pelos demais métodos. Esses resultados indicam que os atributos identificados pelo Integrated Gradients apresentam elevada contribuição para as decisões realizadas pelas GNNs, uma vez que o mascaramento dessas features provoca reduções consistentes na confiança das predições.

Quando comparados aos resultados obtidos na análise de estabilidade, observa-se um com-

portamento interessante. O Integrated Gradients foi o método que apresentou simultaneamente os maiores níveis de estabilidade e fidelidade, indicando que suas explicações são não apenas consistentes entre diferentes variantes do modelo, mas também altamente representativas do processo de decisão da GNN. Esse resultado reforça a hipótese de que métodos baseados na integração de gradientes produzem explicações mais robustas e confiáveis para tarefas de classificação de nós.

Por outro lado, o GraphLIME apresentou um comportamento distinto. Apesar de ter obtido resultados intermediários de estabilidade, sua fidelidade permaneceu próxima de zero em praticamente todos os experimentos. Isso demonstra que produzir explicações semelhantes entre diferentes variantes não implica, necessariamente, que essas explicações representem corretamente os fatores utilizados pela GNN durante a classificação. Em outras palavras, um método pode apresentar elevada estabilidade e, ainda assim, selecionar atributos pouco relevantes para a decisão do modelo.

O GNNExplainer apresentou desempenho intermediário em ambas as análises. Embora suas explicações sejam mais representativas da decisão da GNN quando comparadas às produzidas pelo GraphLIME, observou-se redução significativa da estabilidade à medida que aumenta a complexidade dos conjuntos de dados. Dessa forma, seus resultados sugerem um equilíbrio entre estabilidade e fidelidade, porém inferior ao observado para o Integrated Gradients.

De maneira geral, os resultados obtidos para os grafos homogêneos indicam que o Integrated Gradients apresentou o melhor desempenho entre todos os métodos avaliados, combinando elevados níveis de estabilidade e fidelidade. O GNNExplainer apresentou desempenho intermediário, enquanto o GraphLIME, apesar de produzir explicações relativamente consistentes entre as variantes, apresentou baixa capacidade de identificar atributos efetivamente relevantes para o processo de decisão das Redes Neurais em Grafos.

5.3.2 *Fidelidade dos grafos heterogêneos*

A avaliação da fidelidade também foi realizada no cenário de grafos heterogêneos utilizando o conjunto de dados DBLP e a arquitetura HAN. Os resultados obtidos são apresentados na Tabela 5.

Assim como observado no cenário homogêneo, o **Integrated Gradients** apresentou o melhor desempenho entre os métodos avaliados. O método obteve fidelidade média de XX, indicando que os atributos identificados como mais importantes exercem influência significativa sobre a

Tabela 4 – Resultados da avaliação de fidelidade dos métodos de explicabilidade homogêneo.

Explicador	Dataset	Modelo	Fidelity	Std	Min	Max
GNNExplainer						
GNNExplainer	Cora	GCN	0.151	0.125	0.122	0.184
GNNExplainer	Cora	GAT	0.112	0.133	0.070	0.162
GNNExplainer	Cora	GraphSAGE	0.115	0.093	0.053	0.171
GNNExplainer	CiteSeer	GCN	0.224	0.205	0.178	0.272
GNNExplainer	CiteSeer	GAT	0.120	0.143	0.047	0.191
GNNExplainer	CiteSeer	GraphSAGE	0.257	0.193	0.206	0.308
GNNExplainer	PubMed	GCN	0.100	0.090	0.072	0.125
GNNExplainer	PubMed	GAT	0.063	0.080	0.039	0.089
GNNExplainer	PubMed	GraphSAGE	0.081	0.076	0.053	0.110
GraphLIME						
GraphLIME	Cora	GCN	-0.002	0.026	-0.009	0.003
GraphLIME	Cora	GAT	-0.005	0.011	-0.010	0.000
GraphLIME	Cora	GraphSAGE	0.010	0.026	-0.003	0.024
GraphLIME	CiteSeer	GCN	0.005	0.029	-0.001	0.012
GraphLIME	CiteSeer	GAT	0.005	0.012	-0.001	0.011
GraphLIME	CiteSeer	GraphSAGE	0.019	0.032	0.006	0.034
GraphLIME	PubMed	GCN	0.014	0.027	0.006	0.022
GraphLIME	PubMed	GAT	0.002	0.009	-0.004	0.008
GraphLIME	PubMed	GraphSAGE	0.009	0.017	0.002	0.015
Integrated Gradients						
Integrated Gradients	Cora	GCN	0.176	0.151	0.154	0.205
Integrated Gradients	Cora	GAT	0.141	0.163	0.101	0.186
Integrated Gradients	Cora	GraphSAGE	0.144	0.111	0.073	0.195
Integrated Gradients	CiteSeer	GCN	0.305	0.218	0.262	0.345
Integrated Gradients	CiteSeer	GAT	0.189	0.190	0.092	0.284
Integrated Gradients	CiteSeer	GraphSAGE	0.339	0.205	0.305	0.368
Integrated Gradients	PubMed	GCN	0.196	0.125	0.177	0.212
Integrated Gradients	PubMed	GAT	0.123	0.128	0.093	0.151
Integrated Gradients	PubMed	GraphSAGE	0.163	0.095	0.126	0.204
LogicXGNN						
LogicXGNN	Cora	GCN	0.040	0.070	-0.002	0.203
LogicXGNN	Cora	GAT	-0.002	0.005	-0.015	0.004
LogicXGNN	Cora	GraphSAGE	0.001	0.026	-0.069	0.049
LogicXGNN	CiteSeer	GCN	0.041	0.073	-0.004	0.219
LogicXGNN	CiteSeer	GAT	-0.002	0.009	-0.025	0.007
LogicXGNN	CiteSeer	GraphSAGE	0.027	0.073	-0.023	0.214
LogicXGNN	PubMed	GCN	0.038	0.094	-0.046	0.367
LogicXGNN	PubMed	GAT	0.011	0.020	0.013	0.073
LogicXGNN	PubMed	GraphSAGE	0.011	0.020	-0.013	0.073

Fonte: Elaborado pelo autor.

decisão da arquitetura HAN. Esse resultado demonstra que o mascaramento dessas features produz reduções consistentes na confiança do modelo para a classe originalmente prevista, evidenciando que o método é capaz de identificar atributos efetivamente relevantes para o processo de classificação.

O método **Saliency** apresentou desempenho intermediário, com fidelidade média de XX. Embora superior ao método baseado em atenção, os resultados indicam que parte dos atributos selecionados possui influência limitada sobre a decisão final da rede, produzindo reduções relativamente pequenas na confiança das predições após o mascaramento das features.

Os menores valores de fidelidade foram observados para o método **Attention-based Explanation**. Nesse caso, o mascaramento dos atributos identificados pelo mecanismo de atenção provocou pouca alteração na confiança das predições realizadas pela arquitetura HAN. Esse comportamento sugere que os pesos de atenção, quando utilizados diretamente como mecanismo de explicabilidade, não necessariamente representam os fatores mais relevantes para o processo de decisão da rede.

Comparando os resultados de estabilidade e fidelidade, observa-se novamente que o **Integrated Gradients** apresentou o melhor equilíbrio entre as duas propriedades. Além de produzir explicações altamente consistentes entre diferentes variantes da arquitetura HAN, o método também identificou atributos que efetivamente influenciam as decisões do modelo. Esse comportamento reforça as conclusões obtidas no cenário homogêneo, indicando que o Integrated Gradients mantém seu desempenho mesmo quando aplicado a grafos compostos por múltiplos tipos de nós e relações.

Entretanto, os experimentos realizados também evidenciaram uma limitação importante da estratégia de fidelidade adotada neste trabalho quando aplicada ao cenário heterogêneo. A métrica utilizada considera apenas o mascaramento dos atributos dos nós, assumindo implicitamente que a informação relevante para a decisão do modelo está concentrada nessas features. No entanto, em Redes Neurais em Grafos heterogêneos, a classificação depende simultaneamente dos atributos dos nós e das diferentes relações existentes entre os múltiplos tipos de entidades presentes no grafo.

Na arquitetura HAN, por exemplo, o processo de propagação de mensagens é fortemente influenciado pelos diferentes meta-caminhos utilizados para conectar autores, artigos, conferências e demais tipos de nós presentes no conjunto de dados. Dessa forma, parte da informação utilizada durante a classificação encontra-se na própria estrutura heterogênea do grafo e não

exclusivamente nos atributos associados aos nós.

Consequentemente, o mascaramento apenas das features pode não provocar uma redução suficientemente representativa na confiança das predições, mesmo quando a explicação identifica corretamente os fatores utilizados pelo modelo. Isso indica que a métrica de fidelidade tradicional pode subestimar a qualidade das explicações produzidas em grafos heterogêneos, uma vez que desconsidera a contribuição estrutural das diferentes relações presentes nesse tipo de representação.

Esses resultados sugerem que a avaliação da fidelidade em grafos heterogêneos constitui um problema ainda em aberto na literatura. Estratégias futuras poderiam considerar não apenas o mascaramento dos atributos dos nós, mas também perturbações sobre as relações e metacaminhos utilizados pela arquitetura, permitindo uma avaliação mais completa da influência de cada componente do grafo sobre as decisões do modelo.

De maneira geral, embora o Integrated Gradients tenha novamente apresentado o melhor desempenho entre os métodos avaliados, os experimentos realizados indicam que a interpretação dos valores de fidelidade em grafos heterogêneos deve ser feita com cautela. Diferentemente do cenário homogêneo, em que os atributos dos nós representam a principal fonte de informação para a classificação, grafos heterogêneos incorporam diferentes tipos de entidades e relações que também participam diretamente do processo de decisão das Redes Neurais em Grafos. Dessa forma, os resultados obtidos reforçam a necessidade de desenvolver métricas de fidelidade específicas para métodos de explicabilidade aplicados a grafos heterogêneos.

Tabela 5 – Resultados da avaliação de fidelidade dos métodos de explicabilidade heterogêneos.

Dataset	Modelo	Explicador	Fidelity	Std	Min	Max
DBLP	HAN	Integrated Gradients	0.000126	0.000320	-0.000210	0.002348
DBLP	HAN	Saliency	0.000047	0.000147	-0.000237	0.002348
DBLP	HAN	Attention-based explanation	-0.000001	0.000021	-0.000241	0.000076

Fonte: Elaborado pelo autor.

5.4 Síntese dos Resultados

Os experimentos realizados neste trabalho permitiram avaliar a confiabilidade de diferentes métodos de explicabilidade para Redes Neurais em Grafos sob duas perspectivas complementares: estabilidade e fidelidade. Enquanto a estabilidade investiga a consistência das explicações diante de pequenas modificações na arquitetura da rede, a fidelidade busca verificar se os atributos

identificados pelos explicadores realmente influenciam as decisões tomadas pelo modelo.

Na análise de estabilidade, observou-se que o **Integrated Gradients** apresentou desempenho consistentemente superior aos demais métodos, tanto no cenário de grafos homogêneos quanto no cenário heterogêneo. Em praticamente todos os experimentos, o método obteve os maiores valores de Similaridade de Jaccard, Overlap@10 e Correlação de Spearman, indicando elevada concordância entre as explicações produzidas pelas diferentes variantes das arquiteturas avaliadas. Esses resultados sugerem que pequenas alterações nos hiperparâmetros dos modelos exercem baixa influência sobre as explicações geradas pelo método.

O **GNNExplainer** apresentou comportamento intermediário, produzindo explicações relativamente consistentes em conjuntos de dados menos complexos, como o Cora, porém com redução significativa da estabilidade à medida que aumentava a complexidade estrutural dos grafos. O **GraphLIME** apresentou estabilidade intermediária e comportamento relativamente uniforme entre os diferentes conjuntos de dados, enquanto os métodos avaliados no cenário heterogêneo baseados em gradientes simples e mecanismos de atenção apresentaram menor consistência entre as variantes da arquitetura HAN.

Na avaliação da fidelidade, o **Integrated Gradients** também apresentou os melhores resultados. Em todos os conjuntos de dados avaliados, o método identificou atributos cuja remoção provocou reduções mais expressivas na confiança das previsões realizadas pelas GNNs. Esse comportamento indica que as explicações produzidas representam de forma mais fiel os fatores efetivamente utilizados pelo modelo durante o processo de classificação.

Em contraste, o **GraphLIME** apresentou valores de fidelidade próximos de zero em praticamente todos os experimentos. Embora tenha produzido explicações relativamente estáveis, o mascaramento dos atributos selecionados provocou pouca alteração na confiança das previsões, indicando que parte das features identificadas possui baixa influência sobre as decisões da rede. Esse resultado evidencia que estabilidade e fidelidade representam propriedades distintas e complementares, demonstrando que um método pode produzir explicações consistentes sem necessariamente representar corretamente o processo decisório da GNN.

Os resultados obtidos para o **LogicXGNN** mostraram um comportamento distinto dos demais explicadores. Apesar da elevada interpretabilidade proporcionada pelas regras lógicas produzidas pelo método, foram observados baixos valores de Similaridade de Jaccard após o mapeamento das regras para os atributos originais. Uma possível explicação para esse comportamento está relacionada ao fato de que o **LogicXGNN** constrói suas regras a partir de representações latentes

aprendidas pela GNN. Como pequenas modificações na arquitetura podem alterar a organização desse espaço latente, o processo de associação entre dimensões latentes e atributos originais tende a variar entre as diferentes variantes do modelo, reduzindo a concordância observada pelas métricas utilizadas neste trabalho.

No cenário heterogêneo, os experimentos também evidenciaram limitações da estratégia de avaliação de fidelidade tradicional. Como a arquitetura HAN realiza a propagação de mensagens considerando simultaneamente atributos dos nós e diferentes tipos de relações representadas pelos meta-caminhos, o mascaramento apenas das features pode não refletir completamente os fatores responsáveis pelas decisões do modelo. Esse resultado sugere que a avaliação da fidelidade em grafos heterogêneos constitui um problema ainda em aberto, indicando a necessidade de métricas que considerem conjuntamente atributos e estrutura relacional.

De maneira geral, os resultados obtidos demonstram que o **Integrated Gradients** foi o método que apresentou o melhor equilíbrio entre estabilidade e fidelidade em todos os cenários avaliados. As explicações produzidas pelo método mostraram-se simultaneamente consistentes entre diferentes variantes das arquiteturas e representativas do processo de decisão das Redes Neurais em Grafos. Dessa forma, entre os métodos investigados neste trabalho, o Integrated Gradients mostrou-se a alternativa mais adequada para aplicações que demandam explicações confiáveis, bem como para estudos que buscam analisar a evolução do aprendizado das Redes Neurais em Grafos por meio da comparação de diferentes variantes arquiteturais.

6 CONCLUSÃO

O presente trabalho teve como objetivo investigar a confiabilidade de diferentes métodos de explicabilidade aplicados a Redes Neurais em Grafos, analisando duas propriedades fundamentais das explicações produzidas: estabilidade e fidelidade. Para isso, foram avaliados diferentes métodos de explicabilidade em arquiteturas homogêneas (GCN, GAT e GraphSAGE) e heterogêneas (HAN), utilizando conjuntos de dados amplamente empregados na literatura. Além disso, foi proposta uma adaptação do método LogicXGNN para possibilitar sua utilização em tarefas de classificação de nós, ampliando seu domínio de aplicação.

Os resultados obtidos demonstraram que o Integrated Gradients apresentou, de forma consistente, o melhor desempenho entre todos os métodos avaliados. Em praticamente todos os experimentos realizados, o método obteve os maiores valores de estabilidade, indicando elevada consistência entre as explicações produzidas por diferentes variantes das arquiteturas, bem como

os maiores valores de fidelidade, evidenciando que os atributos identificados possuem influência significativa sobre as decisões tomadas pelos modelos. Esses resultados sugerem que o Integrated Gradients produz explicações simultaneamente consistentes e representativas do processo de decisão das Redes Neurais em Grafos.

O GNNExplainer apresentou desempenho intermediário, produzindo explicações relativamente fiéis, porém mais sensíveis às pequenas alterações realizadas nas arquiteturas das GNNs, principalmente nos conjuntos de dados mais complexos. Esse comportamento indica que o método pode ser adequado para aplicações em que pequenas variações entre diferentes versões do modelo não representem um problema significativo, especialmente em cenários menos complexos.

O GraphLIME apresentou resultados distintos. Embora tenha produzido explicações relativamente estáveis entre as variantes avaliadas, seus baixos valores de fidelidade indicam que os atributos selecionados exercem pouca influência sobre as decisões dos modelos segundo a métrica utilizada neste trabalho. Esse resultado evidencia que estabilidade e fidelidade são propriedades complementares e que a consistência entre explicações não garante, necessariamente, que elas representem corretamente o processo decisório da rede.

A adaptação realizada no LogicXGNN permitiu aplicar um método originalmente desenvolvido para classificação de grafos ao problema de classificação de nós. Apesar de suas explicações apresentarem elevada interpretabilidade por meio de regras lógicas, os experimentos mostraram limitações quando avaliadas pelas métricas tradicionais de estabilidade. Os resultados sugerem que essas limitações estão relacionadas ao fato de que o método constrói suas regras a partir de representações latentes aprendidas pela GNN, cujo mapeamento para os atributos originais pode variar entre diferentes variantes do modelo. Ainda assim, a adaptação desenvolvida amplia as possibilidades de utilização do LogicXGNN e representa uma contribuição metodológica deste trabalho.

Outra contribuição importante desta pesquisa foi a introdução da etapa de conformidade entre variantes dos modelos antes da avaliação da estabilidade. Essa etapa garantiu que as comparações entre explicações fossem realizadas apenas entre modelos que apresentavam comportamento semelhante em relação às predições, reduzindo a influência de diferenças decorrentes do próprio processo de classificação. Além disso, os experimentos realizados no cenário heterogêneo evidenciaram limitações da estratégia tradicional de avaliação da fidelidade, indicando que métricas baseadas exclusivamente no mascaramento dos atributos dos nós podem não capturar

completamente a influência exercida pelas diferentes relações presentes em grafos heterogêneos.

De maneira geral, os resultados obtidos indicam que o Integrated Gradients constitui a alternativa mais adequada entre os métodos investigados para aplicações que demandam explicações confiáveis, especialmente em cenários que envolvem a comparação entre diferentes variantes de arquiteturas de Redes Neurais em Grafos. A elevada estabilidade observada torna o método particularmente interessante para estudos que buscam analisar a evolução do aprendizado dos modelos ao longo de modificações em sua arquitetura ou em seus hiperparâmetros.

Como perspectivas para trabalhos futuros, pretende-se ampliar a comparação experimental incluindo outros métodos de explicabilidade recentemente propostos para Redes Neurais em Grafos, bem como investigar arquiteturas mais modernas de GNNs e conjuntos de dados adicionais. Também se mostra promissora a investigação de novas métricas de estabilidade e fidelidade que considerem explicitamente a influência da estrutura do grafo, das arestas e dos diferentes tipos de relações presentes em grafos heterogêneos. Por fim, pretende-se explorar estratégias de avaliação específicas para métodos baseados em regras simbólicas, como o LogicXGNN, permitindo uma análise mais adequada de explicações construídas a partir de representações latentes.

REFERÊNCIAS

- GENG, A.; AL. et. Logicxgnn: Towards interpretable graph neural networks via logical rule extraction. **arXiv preprint arXiv:2503.19476**, 2025.
- HAMILTON, W. L.; YING, R.; LESKOVEC, J. Inductive representation learning on large graphs. In: **Proceedings of the 31st Conference on Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. p. 1025–1035.
- HUANG, Q.; YAMAGUCHI, Y.; FUKUMOTO, J. Graphlime: Local interpretable model explanations for graph neural networks. **arXiv preprint arXiv:2001.06216**, 2020.
- JACCARD, P. Étude comparative de la distribution florale dans une portion des alpes et des jura. **Bulletin de la Société Vaudoise des Sciences Naturelles**, v. 37, p. 547–579, 1901.
- JI, H.; SHI, C.; WANG, X.; YANG, B.; LI, Y. Heterogeneous graph benchmark: Datasets, benchmarks, and analysis. In: **Proceedings of the IEEE International Conference on Data Mining (ICDM)**. [S.l.: s.n.], 2020.
- KIPF, T. N.; WELING, M. Semi-supervised classification with graph convolutional networks. In: **Proceedings of the 5th International Conference on Learning Representations (ICLR)**. Toulon, França: [s.n.], 2017.
- SEN, P.; NAMATA, G.; BILGIC, M.; GETOOR, L.; GALLAGHER, B.; ELIASSI-RAD, T. Collective classification in network data. **AI Magazine**, v. 29, n. 3, p. 93–106, 2008.
- SPEARMAN, C. The proof and measurement of association between two things. **The American Journal of Psychology**, v. 15, n. 1, p. 72–101, 1904.
- SUNDARARAJAN, M.; TALY, A.; YAN, Q. Axiomatic attribution for deep networks. In: **Proceedings of the 34th International Conference on Machine Learning (ICML)**. [S.l.: s.n.], 2017. v. 70, p. 3319–3328.
- VELIČKOVIĆ, P.; CUCURULL, G.; CASANOVA, A.; ROMERO, A.; LIÒ, P.; BENGIO, Y. Graph attention networks. In: **Proceedings of the 6th International Conference on Learning Representations (ICLR)**. Vancouver, Canadá: [s.n.], 2018.
- WANG, X.; JI, H.; SHI, C.; WANG, B.; YE, Y.; CUI, P.; YU, P. S. Heterogeneous graph attention network. In: **Proceedings of The World Wide Web Conference (WWW)**. [S.l.: s.n.], 2019. p. 2022–2032.
- YING, R.; BOURGEOIS, D.; YOU, J.; ZITNIK, M.; LESKOVEC, J. Gnnexplainer: Generating explanations for graph neural networks. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2019. v. 32.
- YUAN, H.; AL. et. Explainability in graph neural networks: A taxonomic survey. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, 2024.
- ZHAO, T.; AL. et. Hgexplainer: Explainable heterogeneous graph neural networks. In: **Proceedings of the 33rd ACM International Conference on Information and Knowledge Management (CIKM)**. [S.l.: s.n.], 2024.

APÊNDICE A – COMPARAÇÕES PAIRWISE

Tabela 6 – Resultados de conformidade entre pares de variantes da arquitetura GAT no conjunto CiteSeer.

Variante	Variante	Conformidade (%)
V1	V2	82.80
V1	V3	85.80
V2	V3	86.20

Fonte: Elaborado pelo autor.